

# Klasifikacija brodova na osnovu slike u 5 kategorija

Natalija Šašić, SW14/2018

Softversko inženjerstvo i informacione tehnologije, Fakultet tehničkih nauka u Novom Sadu

Mentor: Veljko Maksimović

## Motivacija

Klasifikacija brodova na osnovu slike predstavlja moderan problem za čije rešavanje postoje mnogobrojne savremene metode. Prepoznavanje plovniha objekata sa satelitskih slika planete Zemlje jedna je vrsta opisanog problema.

Iako je poznato da postoje obavezni GPS uređaji na svakom brodu u pokretu, ilegalni pokušaji prevoženja tereta vodenim saobraćajem takođe treba da se detektuju.

Opisani projekat se bavi finijom klasifikacijom slika brodova koje se mogu napraviti iz perspektive luke u koju pristižu. Njen značaj može biti veliki za ubrzanje dokumentovanja pristiglih plovila.

## Metod

Opisani projekat koristi konvolucionu neuronsku mrežu za klasifikaciju brodova iz skupa podataka.

Za razliku od običnih neuronskih mreža, za ulazne podatke postavljamo slike, kod kojih se radi izdvajanje specijalnih karakteristika. Karakteristike ("features") se izdvajaju pomoću filtera.

Pri konstruisanju neuronske mreže, korišćeni su konvolutivni slojevi koji koriste ReLu aktivacionu funkciju. Poslednji sloj, potpuno povezani, koristi SoftMax aktivacionu funkciju.

Slojevi sažimanja koji se pojavljuju u mreži koriste MaxPooling metod.

Korišćena je biblioteka Keras koja se oslanja na Tensorflow biblioteku, u jeziku Python.

Metoda optimizacije koju Keras biblioteka pruža, a koja je korišćena u opisanom sistemu jeste RMSprop.

## Ulazni podaci



## Podaci

Podaci su preuzeti sa sajta kaggle.com pod nazivom Game of Deep Learning: Ship datasets. Ovaj skup podataka se koristio na takmičenju u veštačkoj inteligenciji. Ukupan broj slika je 6252 u trening i validacionom skupu zajedno, a 2680 u testnom skupu.

Skup podataka sadrži slike 5 različitih vrsta brodova. To su: kruzeri, tankeri, nosači, vojni i teretni brodovi. 10% priloženih slika spada u validacioni skup podataka.

Opisani projekat je trenirao mrežu u 8 epoha.

## Rezultati

Accuracy, odnosno preciznost mreže na kraju prve epohe treniranja jeste 0.3928, u trećoj sesiji je 0.6248 što uz podatke o petoj sesiji(0.7202) i poslednjoj, osmoj (0.8016) prikazuje stabilan rast. Loss je na kraju prve epohe 1.4868, a na kraju poslednje 0.5140 . Preciznost nad validacionim podacima je 0.7636.

## Zaključak

Sistem ima zadovoljavajuće performanse. Tehnike za unapređenje mreže mogu da se baziraju na povećanju broja slojeva, strateškom kombinovanju slojeva sažimanja sa konvolutivnim slojevima, i eksperimentisanje sa unapred pripremljenim metodama optimizacije koje keras nudi. Još jedna, sigurna metoda za poboljšanje performansi jeste duže treniranje mreže, odnosno povećanje broja epoha treniranja. Sa poslednjom idejom oprezno, jer postoji rizik od pretreniranja mreže.